

Universidad del Valle de Guatemala

# **Laboratorio 7**

## **Spark MLlib**

Avance de análisis exploratorio y segmentación

Milton Polanco  
Osman de León

Data Science  
24 de septiembre de 2026

## Resumen

Este avance desarrolla las actividades 1 a 4 del laboratorio con las bases de Personas de la Encuesta Nacional de Empleo e Ingresos Continua. Se armonizaron los cuatro trimestres de 2025 y el primer trimestre de 2026, se aplicaron los filtros solicitados, se describió la población analítica de 2025 y se ajustaron modelos KMeans con dos especificaciones. El conjunto de 2025 quedó formado por 53,025 registros elegibles. La solución seleccionada utiliza edad, antigüedad y horas habituales con dos clusters y una silueta de 0.5547.

Las métricas son no ponderadas. Por tanto, describen los registros analizados y no deben interpretarse como estimaciones oficiales del mercado laboral guatemalteco. El primer trimestre de 2026 se preparó y guardó por separado para la evaluación final, pero no interviene en los resultados de este avance.

## 1 Datos y preparación

### 1.1 Archivos y período

Se descargaron las cinco bases de Personas y sus diccionarios desde el sitio del Instituto Nacional de Estadística. Cada Excel se leyó por separado con pandas y solo se conservaron las variables requeridas. Después se creó un DataFrame de Spark con tipos explícitos. La procedencia se registró en *archivo\_origen*, *periodo\_archivo*, *anio\_archivo* y *trimestre\_calendario*.

| Período | Registros originales | Registros analíticos | Conservado |
|---------|----------------------|----------------------|------------|
| 2025T1  | 51,588               | 13,419               | 26.01%     |
| 2025T2  | 51,167               | 13,492               | 26.37%     |
| 2025T3  | 51,583               | 13,450               | 26.07%     |
| 2025T4  | 49,338               | 12,664               | 25.67%     |
| 2026T1  | 49,843               | 13,258               | 26.60%     |

Tabla 1. Registros antes y después de los filtros.

El cuarto trimestre de 2025 contiene 302 columnas, mientras que los demás archivos contienen 270. Algunas variables también ocupan posiciones diferentes. Una unión por posición podría mezclar campos sin relación; por ello se utilizó *unionByName*. El valor original de *TRIMESTRE* se conservó, pero el calendario se asignó a partir del archivo. En 2025T2 existen 175 registros con valor original 2, de modo que restar uno no resuelve la identificación del período.

### 1.2 Faltantes y filtros

| Variable                                     | Faltantes | Porcentaje |
|----------------------------------------------|-----------|------------|
| P05D01                                       | 150,651   | 73.97%     |
| OCUPADOS, P05C16, P05C07A, P05C07B y P05H01A | 115,454   | 56.69%     |
| P03A03A                                      | 26,344    | 12.93%     |
| P02A03 y DOMINIO                             | 0         | 0.00%      |

Tabla 2. Faltantes en los cuatro archivos de 2025 antes de aplicar filtros.

El salario está vacío en 73.97% de los registros. Las variables laborales vinculadas con ocupación, categoría, antigüedad y horas presentan 56.69% de faltantes. La coincidencia es consistente con saltos del cuestionario. Una ausencia por salto no equivale a una no respuesta; su interpretación requiere revisar el flujo de la boleta.

| Orden | Criterio                                             | Excluidos | Restantes |
|-------|------------------------------------------------------|-----------|-----------|
| 1     | Edad numérica, finita y mayor o igual a 15           | 62,886    | 140,790   |
| 2     | Persona ocupada (OCUPADOS = 1)                       | 52,568    | 88,222    |
| 3     | Categoría asalariada (P05C16 entre 1 y 4)            | 35,197    | 53,025    |
| 4     | Salario numérico, finito y positivo                  | 0         | 53,025    |
| 5     | Años de antigüedad numéricos, finitos y no negativos | 0         | 53,025    |
| 6     | Meses de antigüedad enteros entre 0 y 11             | 0         | 53,025    |
| 7     | Antigüedad calculada menor o igual a la edad         | 0         | 53,025    |
| 8     | Horas habituales numéricas, finitas y entre 1 y 168  | 0         | 53,025    |

*Tabla 3. Exclusiones secuenciales para 2025.*

El criterio de edad excluye 62,886 registros; después se excluyen 52,568 personas no ocupadas y 35,197 ocupados que no pertenecen a las cuatro categorías asalariadas. Los 53,025 registros restantes cumplen los criterios de salario, antigüedad y horas. En 2026T1 se obtienen 13,258 registros con el mismo procedimiento.

### 1.3 Claves y alcance

No se encontraron claves repetidas para la combinación período, hogar y persona. Por ello no fue necesario resolver repeticiones exactas ni registros en conflicto. Una persona observada en trimestres diferentes no se considera duplicada: cada fila corresponde a una medición distinta dentro del diseño longitudinal.

El número de filas filtradas no representa a todos los trabajadores del país. El análisis se limita a personas de 15 años o más, ocupadas, asalariadas, con salario positivo y datos numéricos válidos. Además, las métricas no usan el factor de expansión. *FACTOR* se conserva para un análisis poblacional posterior que respete el diseño muestral.

## 2 Estadística descriptiva

### 2.1 Variables numéricas

| Variable                    | n      | Media    | Mediana  | DE       | Mín. | Máx.     | P25     | P75     | P95     |
|-----------------------------|--------|----------|----------|----------|------|----------|---------|---------|---------|
| Salario mensual (Q)         | 53,025 | 3,421.68 | 3,000.00 | 2,902.11 | 1.0  | 99,000.0 | 1,800.0 | 4,000.0 | 8,000.0 |
| Edad (años)                 | 53,025 | 35.19    | 33.00    | 13.52    | 15.0 | 89.0     | 24.0    | 44.0    | 61.0    |
| Antigüedad (años)           | 53,025 | 5.56     | 2.00     | 7.83     | 0.0  | 70.0     | 0.5     | 7.0     | 22.0    |
| Horas habituales por semana | 53,025 | 46.31    | 45.00    | 18.63    | 1.0  | 126.0    | 40.0    | 55.0    | 80.0    |

Tabla 4. Estadísticas descriptivas de los 53,025 registros elegibles de 2025.

El salario medio es Q3,421.68 y la mediana Q3,000.00. La diferencia de Q421.68, el máximo de Q99,000 y el percentil 95 de Q8,000 muestran una distribución sesgada a la derecha. Los extremos se conservaron, como exige el enunciado. La escala logarítmica de la figura facilita la lectura visual sin transformar la variable empleada en los cálculos.





Figura 1. Distribución del salario mensual en una muestra fija de 10,000 registros. El eje horizontal usa escala logarítmica.

## 2.2 Distribuciones categóricas



*Figura 2. Registros por categoría ocupacional, nivel educativo y dominio.*

El empleo en empresa privada reúne 54.13% de los registros, seguido por jornaleros o peones con 26.10%. Los niveles más frecuentes son diversificado (31.78%) y primaria (29.84%). El dominio urbano metropolitano representa 41.63%, el resto urbano 37.99% y el rural nacional 20.38%.

## 2.3 Salario por educación y categoría

| Nivel educativo | n      | Salario mediano |
|-----------------|--------|-----------------|
| Doctorado       | 60     | Q12,000         |
| Maestría        | 771    | Q10,000         |
| Superior        | 6,818  | Q5,000          |
| Diversificado   | 16,851 | Q3,600          |
| Básico          | 8,249  | Q2,800          |
| Primaria        | 15,822 | Q2,200          |
| Preprimaria     | 459    | Q2,160          |
| Ninguno         | 3,995  | Q1,500          |

Tabla 5. Salario mediano por nivel educativo.

| Categoría ocupacional       | n      | Salario mediano |
|-----------------------------|--------|-----------------|
| Empleado de gobierno        | 6,575  | Q5,000          |
| Empleado de empresa privada | 28,702 | Q3,560          |
| Jornalero o peón            | 13,842 | Q1,800          |
| Servicio doméstico          | 3,906  | Q1,000          |

Tabla 6. Salario mediano por categoría ocupacional.

La mediana aumenta desde Q1,500 entre quienes no tienen nivel aprobado hasta Q5,000 en educación superior y Q10,000 en maestría. El doctorado alcanza Q12,000, pero solo contiene 60 observaciones. Por categoría ocupacional, la mediana es Q5,000 en gobierno, Q3,560 en empresa privada, Q1,800 entre jornaleros y Q1,000 en servicio doméstico. Estas diferencias son asociaciones descriptivas y no efectos causales.




Figura 3. Salario mediano por nivel educativo y categoría ocupacional.

## 2.4 Cambios entre trimestres

| Período | Registros | Salario mediano |
|---------|-----------|-----------------|
| 2025T1  | 13,419    | Q3,000          |
| 2025T2  | 13,492    | Q3,000          |
| 2025T3  | 13,450    | Q3,200          |
| 2025T4  | 12,664    | Q3,200          |

Tabla 7. Tamaño analítico y salario mediano por trimestre.

El tamaño se mantiene cerca de 13,400 registros en los primeros tres trimestres y baja a 12,664 en 2025T4. La mediana salarial pasa de Q3,000 en los dos primeros cortes a Q3,200 en los dos últimos. La comparación no ajusta por cambios en la composición de los registros.




Figura 4. Tamaño de la muestra analítica y salario mediano por trimestre.

### 3 Relaciones entre variables numéricas

|            | Salario | Edad   | Antigüedad | Horas  |
|------------|---------|--------|------------|--------|
| Salario    | 1.000   | 0.147  | 0.180      | 0.076  |
| Edad       | 0.147   | 1.000  | 0.487      | -0.105 |
| Antigüedad | 0.180   | 0.487  | 1.000      | -0.062 |
| Horas      | 0.076   | -0.105 | -0.062     | 1.000  |

Tabla 8. Correlaciones de Pearson calculadas con todos los registros elegibles de 2025.




Figura 5. Mapa de calor de la matriz de correlaciones.

La antigüedad presenta la mayor asociación lineal con el salario, aunque es débil ( $r = 0.180$ ). Le siguen la edad ( $r = 0.147$ ) y las horas semanales ( $r = 0.076$ ). Ninguna de estas variables explica por sí sola una parte grande de la variación salarial. Edad y antigüedad tienen una relación positiva moderada ( $r = 0.487$ ), coherente con el tiempo disponible para acumular permanencia laboral.

## 4 Segmentación con KMeans

### 4.1 Especificaciones y criterio

Se compararon dos especificaciones. La primera usa edad, antigüedad y horas habituales; la segunda agrega salario mensual. Todas las variables se estandarizaron con media cero y desviación estándar uno. Para cada especificación se ajustaron modelos con K entre 2 y 5, semilla 20260924 e inicialización k-means||.

Se seleccionó la mayor silueta entre soluciones cuyo cluster más pequeño contiene al menos 5% de los registros. La restricción evita elegir una solución que solo aisle unos pocos salarios extremos. En resultados cercanos se favorece la solución más simple.

| Especificación | K | Silueta | Cluster mínimo |
|----------------|---|---------|----------------|
| Sin salario    | 2 | 0.5547  | 27.51%         |
| Sin salario    | 3 | 0.4721  | 19.03%         |
| Sin salario    | 4 | 0.4760  | 12.95%         |
| Sin salario    | 5 | 0.4421  | 5.13%          |
| Con salario    | 2 | 0.5148  | 27.00%         |
| Con salario    | 3 | 0.4888  | 5.42%          |
| Con salario    | 4 | 0.3753  | 4.41%          |
| Con salario    | 5 | 0.3881  | 0.57%          |

Tabla 9. Evaluación de las alternativas de KMeans.




Figura 6. Silueta para cada especificación y número de clusters.

K = 2 sin salario obtuvo la mayor silueta (0.5547); con salario, K = 2 alcanzó 0.5148. En K = 4 y K = 5 con salario aparecen grupos menores al 5%, señal de sensibilidad a los extremos. Se eligió K = 2 con edad, antigüedad y horas, y el salario se reservó para describir los perfiles.

## 4.2 Perfiles seleccionados

| Cluster | n      | %      | Edad media | Antigüedad media | Horas medias | Salario mediano |
|---------|--------|--------|------------|------------------|--------------|-----------------|
| 0       | 14,586 | 27.51% | 51.3       | 13.8             | 41.3         | Q3,466          |
| 1       | 38,439 | 72.49% | 29.1       | 2.4              | 48.2         | Q3,000          |

Tabla 10. Características principales de los dos perfiles.




Figura 7. Participación de los registros en cada cluster.

El cluster 0 contiene 14,586 registros (27.51%). Su edad media es 51.3 años, la antigüedad media 13.8 años y la jornada media 41.3 horas; el salario mediano es Q3,466. Se interpreta como un perfil de mayor edad y permanencia, con jornadas algo más cortas. El nivel educativo modal es primaria.

El cluster 1 contiene 38,439 registros (72.49%). Su edad media es 29.1 años, la antigüedad media 2.4 años y la jornada media 48.2 horas; el salario mediano es Q3,000. Se interpreta como un perfil joven y de poca antigüedad, con jornadas más largas. El nivel educativo modal es diversificado.

En ambos grupos predominan el empleo en empresa privada y el dominio urbano metropolitano. Estas categorías son modas y no describen a todos los integrantes del cluster. La separación se explica principalmente por edad y antigüedad, no por una regla salarial.

## 5 Hallazgos del avance

La preparación produce un conjunto estable entre trimestres: cerca de 26% de cada archivo cumple la definición analítica. No se detectaron claves repetidas dentro de los períodos y el primer trimestre de 2026 quedó preparado con las mismas reglas.

El salario tiene asimetría positiva y diferencias claras entre niveles educativos y categorías ocupacionales. Las asociaciones lineales con edad, antigüedad y horas son débiles; la mayor es la de antigüedad. Estos resultados anticipan que la predicción salarial requerirá combinar variables numéricas y categóricas, pero esa etapa no forma parte de este avance.

Para segmentar perfiles conviene excluir el salario de la formación de clusters. Al incluirlo, la silueta disminuye y las soluciones con más grupos aíslan subconjuntos muy pequeños. La solución de dos clusters resume una diferencia interpretable entre trabajadores jóvenes con poca antigüedad y trabajadores de mayor edad con permanencia más larga.

## **Fuente**

Instituto Nacional de Estadística de Guatemala. *Encuesta Nacional de Empleo e Ingresos Continua*. Bases de Personas y diccionarios de 2025 y primer trimestre de 2026. <https://www.ine.gob.gt/encuesta-nacional-de-empleo-e-ingresos/>