

Universidad del Valle de Guatemala

Laboratorio 7

Spark MLlib

Análisis exploratorio, segmentación y modelado del salario mensual

Milton Polanco
Osman de León

Data Science

27 de septiembre de 2026

Resumen

Este reporte reúne el trabajo completo del laboratorio con las bases de Personas de la Encuesta Nacional de Empleo e Ingresos Continua. Armonizamos los cuatro trimestres de 2025 y el primero de 2026, aplicamos los filtros del enunciado y describimos la población analítica de 2025, que quedó en 53,025 registros. Con edad, antigüedad y horas habituales ajustamos KMeans y nos quedamos con dos clusters (silueta de 0.5547). Después estimamos el salario mensual con una regresión lineal y con un Random Forest, escogiendo los hiperparámetros con 2025T4 y evaluando al final en 2026T1.

Random Forest resultó mejor. En la prueba obtuvo un RMSE de Q1,954.44 y un R^2 de 0.5355, contra Q2,163.75 y 0.4307 de la regresión lineal. Los dos modelos sobreestiman un poco los salarios bajos y subestiman bastante los altos.

Las métricas no son ponderadas. Describen los registros analizados y no deben leerse como estimaciones oficiales del mercado laboral guatemalteco.

1. Datos y preparación

1.1. Archivos y período

Se descargaron las cinco bases de Personas y sus diccionarios desde el sitio del Instituto Nacional de Estadística. Cada Excel se leyó por separado con pandas y solo se conservaron las variables requeridas. Después se creó un DataFrame de Spark con tipos explícitos. La procedencia se registró en `archivo_origen`, `periodo_archivo`, `anio_archivo` y `trimestre_calendario`.

Período	Registros originales	Registros analíticos	Conservado
2025T1	51,588	13,419	26.01 %
2025T2	51,167	13,492	26.37 %
2025T3	51,583	13,450	26.07 %
2025T4	49,338	12,664	25.67 %
2026T1	49,843	13,258	26.60 %

Tabla 1. Registros antes y después de los filtros.

El cuarto trimestre de 2025 tiene 302 columnas y los demás archivos 270. Algunas variables, además, ocupan posiciones distintas. Una unión por posición podría mezclar campos que no tienen relación, así que usamos `unionByName`. El valor original de `TRIMESTRE` se conservó, pero el trimestre calendario se asignó a partir del archivo. En 2025T2 hay 175 registros con valor original 2, de modo que restar uno no resuelve la identificación del período.

1.2. Faltantes y filtros

Variable	Faltantes	Porcentaje
P05D01	150,651	73.97 %
OCUPADOS, P05C16, P05C07A, P05C07B y P05H01A	115,454	56.69 %
P03A03A	26,344	12.93 %
P02A03 y DOMINIO	0	0.00 %

Tabla 2. Faltantes en los cuatro archivos de 2025 antes de aplicar filtros.

El salario está vacío en 73.97 % de los registros. Las variables laborales de ocupación, categoría, antigüedad y horas tienen 56.69 % de faltantes. Que coincidan es consistente con saltos del cuestionario. Una ausencia por salto no es lo mismo que una no respuesta, y para interpretarla habría que revisar el flujo de la boleta.

Orden	Criterio	Excluidos	Restantes
1	Edad numérica, finita y mayor o igual a 15	62,886	140,790
2	Persona ocupada (OCUPADOS = 1)	52,568	88,222
3	Categoría asalariada (P05C16 entre 1 y 4)	35,197	53,025
4	Salario numérico, finito y positivo	0	53,025
5	Años de antigüedad numéricos, finitos y no negativos	0	53,025
6	Meses de antigüedad enteros entre 0 y 11	0	53,025
7	Antigüedad calculada menor o igual a la edad	0	53,025
8	Horas habituales numéricas, finitas y entre 1 y 168	0	53,025

Tabla 3. Exclusiones secuenciales para 2025.

El criterio de edad excluye 62,886 registros, después salen 52,568 personas no ocupadas y 35,197 ocupados que no pertenecen a las cuatro categorías asalariadas. Los 53,025 registros restantes cumplen los criterios de salario, antigüedad y horas. En 2026T1 el mismo procedimiento deja 13,258 registros.

1.3. Claves y alcance

No encontramos claves repetidas para la combinación período, hogar y persona, por lo que no hubo que resolver repeticiones exactas ni registros en conflicto. Una persona observada en trimestres distintos no cuenta como duplicada: cada fila es una medición distinta dentro del diseño longitudinal.

El número de filas filtradas no representa a todos los trabajadores del país. El análisis se limita a personas de 15 años o más, ocupadas, asalariadas, con salario positivo y datos numéricos válidos. Además, las métricas no usan el factor de expansión. FACTOR se conserva para un análisis poblacional posterior que respete el diseño muestral.

2. Estadística descriptiva

2.1. Variables numéricas

Variable	n	Media	Mediana	DE	Mín.	Máx.	P25	P75	P95
Salario mensual (Q)	53,025	3,421.68	3,000.00	2,902.11	1.0	99,000.0	1,800.0	4,000.0	8,000.0
Edad (años)	53,025	35.19	33.00	13.52	15.0	89.0	24.0	44.0	61.0
Antigüedad (años)	53,025	5.56	2.00	7.83	0.0	70.0	0.5	7.0	22.0
Horas por semana	53,025	46.31	45.00	18.63	1.0	126.0	40.0	55.0	80.0

Tabla 4. Estadísticas descriptivas de los 53,025 registros elegibles de 2025.

El salario medio es Q3,421.68 y la mediana Q3,000.00. La diferencia de Q421.68, el máximo de Q99,000 y el percentil 95 de Q8,000 muestran una distribución sesgada a la derecha. Los extremos se conservaron, como pide el enunciado. La escala logarítmica de la figura ayuda a leer la parte central sin transformar la variable que se usa en los cálculos.




Figura 1. Distribución del salario mensual en una muestra fija de 10,000 registros. El eje horizontal usa escala logarítmica.

2.2. Distribuciones categóricas




Figura 2. Registros por categoría ocupacional, nivel educativo y dominio.

El empleo en empresa privada reúne 54.13 % de los registros, seguido por jornaleros o peones con 26.10 %. Los niveles más frecuentes son diversificado (31.78 %) y primaria (29.84 %). El dominio urbano metropolitano representa 41.63 %, el resto urbano 37.99 % y el rural nacional 20.38 %.

2.3. Salario por educación y categoría

Nivel educativo	n	Salario mediano
Doctorado	60	Q12,000
Maestría	771	Q10,000
Superior	6,818	Q5,000
Diversificado	16,851	Q3,600
Básico	8,249	Q2,800
Primaria	15,822	Q2,200
Preprimaria	459	Q2,160
Ninguno	3,995	Q1,500

Tabla 5. Salario mediano por nivel educativo.

Categoría ocupacional	n	Salario mediano
Empleado de gobierno	6,575	Q5,000
Empleado de empresa privada	28,702	Q3,560
Jornalero o peón	13,842	Q1,800
Servicio doméstico	3,906	Q1,000

Tabla 6. Salario mediano por categoría ocupacional.

La mediana sube desde Q1,500 entre quienes no tienen nivel aprobado hasta Q5,000 en educación superior y Q10,000 en maestría. El doctorado llega a Q12,000, pero solo tiene 60 observaciones. Por categoría ocupacional, la mediana es Q5,000 en gobierno, Q3,560 en empresa privada, Q1,800 entre jornaleros y Q1,000 en servicio doméstico. Son asociaciones descriptivas, no efectos causales.




Figura 3. Salario mediano por nivel educativo y categoría ocupacional.

2.4. Cambios entre trimestres

Período	Registros	Salario mediano
2025T1	13,419	Q3,000
2025T2	13,492	Q3,000
2025T3	13,450	Q3,200
2025T4	12,664	Q3,200

Tabla 7. Tamaño analítico y salario mediano por trimestre.

El tamaño se mantiene cerca de 13,400 registros en los primeros tres trimestres y baja a 12,664 en 2025T4. La mediana salarial pasa de Q3,000 en los dos primeros cortes a Q3,200 en los dos últimos. La comparación no ajusta por cambios en la composición de los registros.




Figura 4. Tamaño de la muestra analítica y salario mediano por trimestre.

3. Relaciones entre variables numéricas

	Salario	Edad	Antigüedad	Horas
Salario	1.000	0.147	0.180	0.076
Edad	0.147	1.000	0.487	-0.105
Antigüedad	0.180	0.487	1.000	-0.062
Horas	0.076	-0.105	-0.062	1.000

Tabla 8. Correlaciones de Pearson calculadas con todos los registros elegibles de 2025.




Figura 5. Mapa de calor de la matriz de correlaciones.

La antigüedad tiene la mayor asociación lineal con el salario, aunque es débil ($r = 0,180$). Le siguen la edad ($r = 0,147$) y las horas semanales ($r = 0,076$). Ninguna de estas variables explica por sí sola una parte grande de la variación salarial. Edad y antigüedad tienen una relación positiva moderada ($r = 0,487$), lo cual tiene sentido: una persona mayor ha tenido más tiempo para acumular años en un mismo trabajo.

4. Segmentación con KMeans

4.1. Especificaciones y criterio

Se compararon dos especificaciones. La primera usa edad, antigüedad y horas habituales; la segunda agrega el salario mensual. Todas las variables se estandarizaron con media cero y desviación estándar uno. Para cada especificación se ajustaron modelos con K entre 2 y 5, semilla 20260924 e inicialización k-means||.

Se seleccionó la mayor silueta entre las soluciones cuyo cluster más pequeño contiene al menos 5 % de los registros. La restricción evita quedarse con una solución que solo aísle unos pocos salarios extremos. Si los resultados estaban cerca, se prefirió la solución más simple.

Especificación	K	Silueta	Cluster mínimo
Sin salario	2	0.5547	27.51 %
Sin salario	3	0.4721	19.03 %
Sin salario	4	0.4760	12.95 %
Sin salario	5	0.4421	5.13 %
Con salario	2	0.5148	27.00 %
Con salario	3	0.4888	5.42 %
Con salario	4	0.3753	4.41 %
Con salario	5	0.3881	0.57 %

Tabla 9. Evaluación de las alternativas de KMeans.




Figura 6. Silueta para cada especificación y número de clusters.

K = 2 sin salario tuvo la mayor silueta (0.5547); con salario, K = 2 llegó a 0.5148. Con K = 4 y K = 5 incluyendo el salario aparecen grupos menores a 5 %, señal de que los valores extremos empiezan a dominar. Elegimos K = 2 con edad, antigüedad y horas, y dejamos el salario para describir los perfiles.

4.2. Perfiles seleccionados

Cluster	n	%	Edad media	Antigüedad media	Horas medias	Salario mediano
0	14,586	27.51 %	51.3	13.8	41.3	Q3,466
1	38,439	72.49 %	29.1	2.4	48.2	Q3,000

Tabla 10. Características principales de los dos perfiles.




Figura 7. Participación de los registros en cada cluster.

El cluster 0 contiene 14,586 registros (27.51 %). Su edad media es 51.3 años, la antigüedad media 13.8 años y la jornada media 41.3 horas; el salario mediano es Q3,466. Es un perfil de mayor edad y permanencia, con jornadas algo más cortas. El nivel educativo modal es primaria.

El cluster 1 contiene 38,439 registros (72.49 %). Su edad media es 29.1 años, la antigüedad media 2.4 años y la jornada media 48.2 horas; el salario mediano es Q3,000. Es un perfil joven y de poca antigüedad, con jornadas más largas. El nivel educativo modal es diversificado.

En ambos grupos predominan el empleo en empresa privada y el dominio urbano metropolitano. Son modas y no describen a todos los integrantes del cluster. La separación se explica sobre todo por edad y antigüedad, no por una regla salarial.

5. Modelado supervisado

5.1. Diseño del experimento

La tarea es estimar `salario_mensual` con seis predictores: edad, antigüedad, horas semanales, nivel educativo, categoría ocupacional y dominio. No usamos identificadores, el factor de expansión, otros ingresos ni la etiqueta de cluster.

Seguimos el uso que el enunciado le da a cada archivo. Los trimestres 2025T1 a 2025T3 sirvieron para entrenar y 2025T4 para validar y escoger hiperparámetros (Tabla 11). Cuando ya teníamos elegida la configuración de cada algoritmo, reajustamos el modelo con los cuatro trimestres de 2025 (53,025 registros) y solo entonces lo evaluamos en 2026T1, que no se usó en ningún paso anterior. Todos los componentes de los pipelines se ajustaron únicamente con datos de entrenamiento: con 2025T1 a T3 durante la selección y con 2025 completo en el reajuste final.

Conjunto	Registros
Entrenamiento (2025T1 a T3)	40,361
Validación (2025T4)	12,664
Prueba final (2026T1)	13,258

Tabla 11. Conjuntos usados en el modelado.

Como modelo de referencia usamos un predictor constante: la media del salario en 2025T1 a T3, aplicada a todos los registros. Es un piso mínimo. Si un modelo no le gana, no está aprendiendo nada útil.

Las tres variables categóricas pasan por un `StringIndexer` (con `handleInvalid = keep`, para que una categoría nueva no rompa la predicción) y un `OneHotEncoder`. Luego un `VectorAssembler` junta esas columnas con las tres numéricas. En la regresión lineal la estandarización la hace el propio modelo; el Random Forest no la necesita. Usamos la semilla 20260924 en todo lo aleatorio y medimos MAE, RMSE y R^2 .

5.2. Regresión lineal

Probamos tres configuraciones de regularización (Tabla 12).

Configuración	(regParam, elasticNetParam)	MAE	RMSE	R^2
Sin regularización	(0.00, 0.00)	1,210.14	2,186.42	0.4257
Ridge ligero	(0.05, 0.00)	1,210.14	2,186.42	0.4257
Elastic net moderado	(0.10, 0.50)	1,210.11	2,186.42	0.4257

Tabla 12. Regresión lineal en validación (2025T4).

Las tres dan prácticamente lo mismo. Con más de 40,000 registros de entrenamiento y pocos predictores, los valores de `regParam` que usamos son demasiado pequeños para mover los coeficientes. El RMSE coincide en los decimales que se muestran y, con el criterio de menor RMSE de validación, quedó la primera, que además es la más simple. Para ver un efecto real de la regularización habría que probar valores bastante más grandes, cosa que no hicimos.

Frente a la referencia (RMSE de Q2,889.57, MAE de Q1,672.50 y R^2 cercano a cero), la regresión lineal baja el RMSE 24.3 % y el MAE 27.6 %. Explica cerca del 43 % de la varianza del salario, lo cual es una mejora clara pero deja más de la mitad sin explicar. Cuadra con las correlaciones débiles de la sección 3: seguramente buena parte de la señal viene del nivel educativo y la categoría ocupacional, que sí mostraron diferencias grandes en la mediana.

5.3. Random Forest

Comparamos dos configuraciones que cambian el número de árboles y la profundidad máxima (Tabla 13).

Configuración	Árboles	Profundidad	MAE	RMSE	R^2
RF ligero	100	5	1,157.45	2,159.85	0.4395
RF profundo	200	10	1,074.60	1,967.40	0.5350

Tabla 13. Random Forest en validación (2025T4).

La configuración profunda ganó con claridad. Como es la más grande de las dos que probamos, es posible que haya algo mejor un poco más allá, pero no lo exploramos. Tampoco calculamos el error en entrenamiento, así que no podemos descartar cierto sobreajuste; lo que sí se ve es que el resultado en 2026T1 casi no cambia respecto al de validación (sección 5.4).

Modelo	MAE	RMSE	R^2
Referencia (media de entrenamiento)	1,672.50	2,889.57	-0.0031
Regresión lineal	1,210.14	2,186.42	0.4257
Random Forest (200 árboles, profundidad 10)	1,074.60	1,967.40	0.5350

Tabla 14. Comparación de modelos en validación (2025T4).

En validación, Random Forest tiene un RMSE 10.0 % menor que la regresión lineal (Q1,967.40 frente a Q2,186.42) y un MAE 11.2 % menor. Una explicación posible es que el bosque puede captar efectos no lineales y combinaciones entre variables que un modelo aditivo no ve: el efecto del nivel educativo es más bien escalonado, y el de la edad o la antigüedad puede depender de la categoría ocupacional. No probamos esto directamente, así que queda como hipótesis.

5.4. Evaluación en 2026T1

Con la configuración elegida de cada algoritmo, reajustamos ambos modelos con 2025 completo y los evaluamos sobre los mismos 13,258 registros de 2026T1 (Tabla 15).

Modelo	MAE	RMSE	R^2
Referencia (media de entrenamiento)	1,716.32	2,873.61	-0.0041
Regresión lineal	1,240.71	2,163.75	0.4307
Random Forest	1,102.62	1,954.44	0.5355

Tabla 15. Métricas en el conjunto de prueba (2026T1).

Random Forest queda mejor en las tres métricas. Frente a la referencia, la regresión lineal reduce el RMSE 24.7 % y Random Forest 32.0 %. Entre los dos modelos, Random Forest baja el RMSE 9.7 % y el MAE 11.1 %.

Los resultados en prueba son casi iguales a los de validación (RMSE de Q2,163.75 y Q1,954.44 contra Q2,186.42 y Q1,967.40) y el orden de los modelos no cambia, así que ambos parecen generalizar bien a un trimestre que no se vio durante el ajuste. Hay que tener presente que los modelos finales se reajustaron con 2025 completo, por lo que la comparación entre validación y prueba no es exactamente entre el mismo modelo.

El MAE de Random Forest equivale a cerca de 37 % del salario mediano de 2025 (Q3,000). Además, el RMSE es bastante mayor que el MAE (Q1,954.44 frente a Q1,102.62), lo que indica que unos pocos errores muy grandes pesan mucho. De eso trata la siguiente sección. Recordemos también que esto estima el salario del período observado; no es un pronóstico del salario futuro de una persona.

6. Análisis de errores

Definimos el residuo como salario real menos salario predicho. Un residuo positivo significa que el modelo subestimó y uno negativo que sobreestimó. Las gráficas usan la misma muestra aleatoria de hasta 5,000 registros de 2026T1 para los dos modelos; las tablas de error se calcularon con los 13,258 registros de prueba.

6.1. Salario real frente a predicho




Figura 8. Salario real frente a salario predicho en 2026T1 (muestra de hasta 5,000 registros). La línea punteada es $y = x$.

En la Figura 8 los dos modelos siguen bastante bien la diagonal hasta unos Q8,000, que es donde está casi todo. Más arriba los salarios reales llegan a Q30,000 y Q50,000, pero las predicciones casi nunca pasan de Q15,000, así que esos puntos quedan muy por encima de la línea. En la regresión lineal se ve además un hueco entre Q8,000 y Q10,500 de salario predicho y un grupo aparte de predicciones más altas. No verificamos de dónde sale; podría venir de las categorías de posgrado, que empujan la predicción hacia arriba de golpe. También hay predicciones cercanas a cero o ligeramente negativas, algo que un salario no puede ser. El Random Forest no tiene ese problema porque sus predicciones son promedios de salarios que sí se observaron.




Figura 9. Residuos (real menos predicho) frente al salario predicho en 2026T1 (misma muestra).

La Figura 9 tiene forma de embudo: los residuos se abren a medida que sube el salario predicho. La frontera diagonal que se ve abajo no es casualidad. Como el salario real no puede ser negativo, el residuo no puede bajar de menos el salario predicho, así que sobreestimar tiene un tope y subestimar no. De ahí sale la cola positiva, con residuos de hasta unos Q35,000 a Q38,000. Es el mismo sesgo a la derecha del salario que vimos en la sección 2.

6.2. Error por nivel educativo y dominio

Nivel educativo	n	Regresión lineal		Random Forest	
		MAE	Error medio	MAE	Error medio
Ninguno	1,016	823.51	109.34	656.76	−56.52
Preprimaria	80	735.21	88.76	614.94	−120.89
Primaria	3,957	870.04	54.56	755.80	40.84
Básico	2,164	894.45	127.77	822.33	126.43
Diversificado	4,117	1,109.31	103.98	1,018.55	126.70
Superior	1,729	2,566.37	295.51	2,289.56	293.37
Maestría	183	5,552.88	−131.50	4,624.13	−268.38
Doctorado	12	12,919.31	6,062.70	11,135.59	5,842.61

Tabla 16. MAE y error medio (real menos predicho, en quetzales) por nivel educativo en 2026T1.

Dominio	n	Regresión lineal		Random Forest	
		MAE	Error medio	MAE	Error medio
Urbano metropolitano	5,632	1,446.09	136.04	1,316.95	171.81
Resto urbano	4,846	1,189.65	134.28	1,042.00	86.58
Rural nacional	2,780	913.64	65.24	774.09	11.05

Tabla 17. MAE y error medio (real menos predicho, en quetzales) por dominio en 2026T1.

Random Forest tiene menor MAE que la regresión lineal en los ocho niveles educativos y en los tres dominios, con reducciones de entre 8 % y 20 % según el grupo. El error crece mucho con el nivel educativo. Para Random Forest, el MAE va de Q615 a Q1,019 entre Ninguno, Preprimaria, Primaria, Básico y Diversificado, sube a Q2,289.56 en Superior, a Q4,624.13 en Maestría y a Q11,135.59 en Doctorado. Tiene lógica: los salarios de posgrado son más altos y más dispersos (medianas de Q10,000 en maestría y Q12,000 en doctorado), así que el mismo error relativo se traduce en un error absoluto mucho mayor.

Doctorado tiene solo 12 registros de prueba y Maestría 183, por lo que esos resultados son inestables y hay que tomarlos con cuidado. En Doctorado el error medio es fuertemente positivo (unos Q6,000 en ambos modelos), es decir, subestimación. En los demás niveles el error medio es pequeño comparado con el MAE (entre −Q268 y Q296): hay una leve subestimación en Básico, Diversificado, Primaria y Superior, una leve sobreestimación en Maestría, y en Ninguno y Preprimaria el signo cambia según el modelo, sin una dirección clara.

Por dominio, el MAE es mayor en el urbano metropolitano (Q1,316.95 en Random Forest), intermedio en el resto urbano (Q1,042.00) y menor en el rural nacional (Q774.09). Probablemente se debe a que los salarios urbanos son más altos y más variables, aunque no lo comprobamos. El error medio es positivo en los tres dominios, una subestimación pequeña frente al MAE.

6.3. Error por tramo de salario

Para ver dónde se concentra el error agrupamos los registros de prueba según su salario real, usando como cortes los percentiles de 2025: P50 = Q3,000, P75 = Q4,000, P90 = Q5,800 y P95 = Q7,500.

Tramo de salario real	n	Regresión lineal		Random Forest	
		MAE	Error medio	MAE	Error medio
Por debajo de P75	8,946	902.52	−452.15	758.14	−414.92
P75 a P90	2,744	1,031.16	253.78	1,005.28	264.58
P90 a P95	692	1,791.77	1,241.04	1,819.22	1,210.20
P95 o más	876	4,915.47	4,666.67	4,359.44	4,071.17

Tabla 18. MAE y error medio (real menos predicho, en quetzales) por tramo de salario real en 2026T1.

Sí hay una tendencia clara: los dos modelos sobreestiman los salarios bajos y subestiman los altos. Por debajo del P75 el error medio es negativo (unos −Q415 en Random Forest y −Q452 en la regresión lineal). Entre P75 y P90 pasa a positivo, entre P90 y P95 supera los Q1,200, y en el P95 o más llega a Q4,071 en Random Forest y Q4,667 en la regresión lineal. El MAE crece en el mismo sentido. En el tramo más alto el error medio es casi igual al MAE, o sea que prácticamente todos los errores son subestimaciones. Ese 6.6 % de los registros aporta alrededor de una cuarta parte del error absoluto total de Random Forest. Los porcentajes de registros por tramo no coinciden exactamente con los nominales, en parte porque los cortes vienen de 2025 y porque hay muchos salarios repetidos en cifras redondas.

Random Forest reduce el error frente a la regresión lineal en tres de los cuatro tramos. En el de P90 a P95 su MAE es apenas mayor (Q1,819.22 contra Q1,791.77). Tampoco elimina el problema: en el tramo más alto sigue subestimando más de Q4,000 en promedio.

Conviene ser cuidadosos con esta lectura. Agrupar por el salario real produce residuos positivos arriba y negativos abajo incluso en un modelo sin sesgo, por el efecto de regresión a la media. Aun así, el tamaño del error y el hecho de que casi ninguna predicción pase de Q15,000 sugieren que las seis variables disponibles no capturan lo que distingue a los salarios más altos. Probablemente pesan factores que no están en la base que usamos, como la ocupación específica o el sector. Como los salarios extremos no se eliminaron, influyen bastante en el RMSE.

7. Discusión final

7.1. Hallazgos

De cada archivo cerca de 26 % cumple la definición analítica y no encontramos claves repetidas en ningún período, así que quedó un conjunto estable de 53,025 registros para 2025 y 13,258 para 2026T1. El salario es muy asimétrico (media de Q3,421.68, mediana de Q3,000 y máximo de Q99,000) y varía bastante con el nivel educativo y la categoría ocupacional, mientras que edad, antigüedad y horas se relacionan con él solo de forma débil. KMeans separó dos perfiles, uno joven con poca antigüedad y otro de mayor edad con más años en el puesto, y en esa separación el salario no participó.

En el modelado, Random Forest con 200 árboles y profundidad 10 fue mejor que la regresión lineal tanto en validación (RMSE de Q1,967.40 contra Q2,186.42) como en la prueba de 2026T1 (RMSE de Q1,954.44, MAE de Q1,102.62 y R^2 de 0.5355, contra Q2,163.75, Q1,240.71 y 0.4307). Frente a la referencia constante, reduce el RMSE 32.0 % y la regresión lineal 24.7 %. La regularización casi no cambió nada en la regresión lineal. Como el desempeño en prueba es muy parecido al de validación, los modelos parecen mantenerse en un trimestre nuevo.

El error crece con el nivel educativo y con el salario. Ambos modelos sobreestiman un poco los salarios bajos y subestiman los altos: en el P95 o más la subestimación promedio supera los Q4,000 y ese tramo aporta cerca de una cuarta parte del error absoluto. Doctorado y Maestría tienen pocos registros y sus errores son inestables.

7.2. Limitaciones

Con solo seis predictores el mejor modelo explica cerca de 54 % de la varianza, así que una parte importante del salario depende de cosas que no están en el modelo. Random Forest quedó en el borde de la búsqueda de hiperparámetros, por lo que una búsqueda más amplia podría mejorarlo, y en la regresión lineal habría que probar penalizaciones más fuertes para saber si la regularización ayuda de verdad. No medimos el error de entrenamiento, así que no podemos decir cuánto sobreajusta el bosque.

Las métricas son no ponderadas y describen solo a personas asalariadas de 15 años o más con salario positivo registrado en la ENEIC. No son estimaciones oficiales del mercado laboral guatemalteco ni una guía de cuánto debería ganar una persona. Las asociaciones que encontramos, tanto en la segmentación como en los modelos, son descriptivas y no permiten hablar de causalidad. FACTOR se conservó durante todo el proceso, pero para representar a la población del país haría falta usar el diseño muestral completo de la encuesta y no solo el factor de expansión.

Fuente

Instituto Nacional de Estadística de Guatemala. Encuesta Nacional de Empleo e Ingresos Continua. Bases de Personas y diccionarios de 2025 y primer trimestre de 2026. <https://www.ine.gob.gt/encuesta-nacional-de-empleo-e-ingresos/>